

Pattern Recognition

University of Chinese Academy of Sciences

Fall 2023

Shiming Xiang, Gaofeng Meng

Homework 1

Chenkai GUO

2023.10.1

1. 请描述最小错误率贝叶斯决策的计算步骤（包含已知条件以及求解任务）；给出一种两类情形下的最小错误率贝叶斯决策规则。

最小错误率贝叶斯决策

已知条件：(1) 类别： $\omega_i, i = 1, \dots, c$

(2) 特征向量： $\mathbf{x} = [x_1, \dots, x_d] \in \mathbb{R}^d$

(3) 先验概率： $P(\omega_i), \sum_{i=1}^c P(\omega_i) = 1$

(4) 概率密度函数/条件概率/似然： $P(\mathbf{x}|\omega_i)$
(一般假设为正态分布或其他分布)

求解任务：对一个给定观测样本 \mathbf{x} 给出其最合理的分类类别，即 $P(\omega_i|\mathbf{x})$

计算步骤：根据贝叶斯公式计算后验概率： $P(\omega_i|\mathbf{x}) = \frac{p(\mathbf{x}|\omega_i)P(\omega_i)}{P(\mathbf{x})} = \frac{p(\mathbf{x}|\omega_i)P(\omega_i)}{\sum_{j=1}^c p(\mathbf{x}|\omega_j)P(\omega_j)}$

决策规则：选择后验概率最大的类别作为输出，即若 $P(\omega_i|\mathbf{x}) = \max_{j=1,2,\dots,c} P(\omega_j|\mathbf{x})$ ，
则 $\mathbf{x} \in \omega_i$

※ 考虑两类情形下，即 $\omega = (\omega_1, \omega_2)$ ：

形式 1：根据贝叶斯公式可得：

$$P(\omega_1|\mathbf{x}) = \frac{p(\mathbf{x}|\omega_1)P(\omega_1)}{P(\mathbf{x})}, P(\omega_2|\mathbf{x}) = \frac{p(\mathbf{x}|\omega_2)P(\omega_2)}{P(\mathbf{x})}$$

若 $\frac{p(\mathbf{x}|\omega_1)P(\omega_1)}{P(\mathbf{x})} > \frac{p(\mathbf{x}|\omega_2)P(\omega_2)}{P(\mathbf{x})}$ ，即当 $p(\mathbf{x}|\omega_1)P(\omega_1) > p(\mathbf{x}|\omega_2)P(\omega_2)$ 时， $\mathbf{x} \in \omega_1$ ；反之 $\mathbf{x} \in \omega_2$

形式 2：若似然比 $l(\mathbf{x}) = \frac{p(\mathbf{x}|\omega_1)}{p(\mathbf{x}|\omega_2)} > \frac{P(\omega_2)}{P(\omega_1)}$ ，则 $\mathbf{x} \in \omega_1$ ；反之 $\mathbf{x} \in \omega_2$

形式 3：若负对数似然比 $-\ln(l(\mathbf{x})) = -\ln\left(\frac{p(\mathbf{x}|\omega_1)}{p(\mathbf{x}|\omega_2)}\right) = -\ln(p(\mathbf{x}|\omega_1)) + \ln(p(\mathbf{x}|\omega_2)) < -\ln\left(\frac{P(\omega_2)}{P(\omega_1)}\right) = \ln(P(\omega_1)) - \ln(P(\omega_2))$ ，则 $\mathbf{x} \in \omega_1$ ；反之 $\mathbf{x} \in \omega_2$

2. 请描述最小风险贝叶斯决策的计算步骤（包含已知条件以及求解任务）；给出一种两类情形下的最小风险贝叶斯决策规则。

最小风险贝叶斯决策

已知条件: (1) 类别: $\omega_i, i = 1, \dots, c$

(2) 特征向量: $\mathbf{x} = [x_1, \dots, x_d] \in \mathbb{R}^d$

(3) 先验概率: $P(\omega_i), \sum_{i=1}^c P(\omega_i) = 1$

(4) 概率密度函数/条件概率/似然: $P(\mathbf{x}|\omega_i)$
(一般假设为正态分布或其他分布)

(5) 决策空间: $\alpha, \alpha_i, i = 1, \dots, a$

(6) 损失函数: $\lambda(\alpha_i|\omega_j)$, 表示当类别为 ω_j 时所采取的决策 α_i 多引起的损失, 简记为 λ_{ij}

求解任务: 给定一个观测样本 \mathbf{x} , 如何对其分类使得其风险/损失最小

计算步骤: (1) 根据贝叶斯公式计算后验概率: $P(\omega_i|\mathbf{x})$

(2) 计算条件风险: $R(\alpha_i|\mathbf{x}) = E[\lambda(\alpha_i|\omega_j)] = \sum_{j=1}^c \lambda(\alpha_i|\omega_j)P(\omega_j|\mathbf{x})$
(条件风险 $R(\alpha_i|\mathbf{x})$ 为随机变量 \mathbf{x} 的函数)

(3) 选择风险最小的决策: $a = \arg \min_{j=1, \dots, a} R(\alpha_j|\mathbf{x})$

决策规则: 最小化期望风险: $\min_{\alpha} R(\alpha) = \min_{\alpha} \int R(\alpha(\mathbf{x})|\mathbf{x}) \cdot p(\mathbf{x}) d\mathbf{x}$

对特定 \mathbf{x} 的类别决策则为选择条件风险 $R(\alpha_i|\mathbf{x})$ 最小的决策

※ 考虑两类情形下, 即 $\omega = (\omega_1, \omega_2), :$

情况一: 不考虑拒实, 即 $\alpha = (\alpha_1, \alpha_2)$

计算类别的条件风险得:

$$\begin{aligned} R(\alpha_1|\mathbf{x}) &= \lambda_{11}P(\omega_1|\mathbf{x}) + \lambda_{12}P(\omega_2|\mathbf{x}) \\ R(\alpha_2|\mathbf{x}) &= \lambda_{21}P(\omega_1|\mathbf{x}) + \lambda_{22}P(\omega_2|\mathbf{x}) \end{aligned}$$

形式 1: 若 $R(\alpha_1|\mathbf{x}) < R(\alpha_2|\mathbf{x})$, 则 $\alpha = \alpha_1$; 反之 $\alpha = \alpha_2$

形式 2: 若 $R(\alpha_1|\mathbf{x}) < R(\alpha_2|\mathbf{x}) \Leftrightarrow \lambda_{11}P(\omega_1|\mathbf{x}) + \lambda_{12}P(\omega_2|\mathbf{x}) < \lambda_{21}P(\omega_1|\mathbf{x}) + \lambda_{22}P(\omega_2|\mathbf{x})$

$\Leftrightarrow (\lambda_{11} - \lambda_{21})P(\omega_1|\mathbf{x}) < (\lambda_{22} - \lambda_{12})P(\omega_2|\mathbf{x})$, 不失一般性, 假设 $\lambda_{11} < \lambda_{21}, \lambda_{22} < \lambda_{12}$,

则得到, 若 $\frac{P(\omega_1|\mathbf{x})}{P(\omega_2|\mathbf{x})} > \frac{\lambda_{22} - \lambda_{12}}{\lambda_{11} - \lambda_{21}}$, 此时 $\alpha = \alpha_1$; 反之 $\alpha = \alpha_2$

形式 3: 因为 $\frac{P(\omega_1|\mathbf{x})}{P(\omega_2|\mathbf{x})} = \frac{P(\mathbf{x}|\omega_1)P(\omega_1)}{P(\mathbf{x}|\omega_2)P(\omega_2)}$, 则若似然比 $l(\mathbf{x}) = \frac{p(\mathbf{x}|\omega_1)}{p(\mathbf{x}|\omega_2)} > \frac{P(\omega_2)}{P(\omega_1)} \cdot \frac{\lambda_{22} - \lambda_{12}}{\lambda_{11} - \lambda_{21}}$, 则 $\alpha = \alpha_1$; 反之 $\alpha = \alpha_2$

形式 4: 考虑 Zero-one Loss: $\lambda(\alpha_i | \omega_j) = \begin{cases} 0, & i = j \\ 1, & i \neq j \end{cases} \quad i, j = 1, 2, \dots, c$

此时 $R(\alpha_i|\mathbf{x}) = \sum_{j=1}^c \lambda(\alpha_i | \omega_j)P(\omega_j | \mathbf{x}) = \sum_{j \neq i} P(\omega_j|\mathbf{x}) = 1 - P(\omega_i|\mathbf{x})$ (此时, 最小风险

贝叶斯决策等价于最小错误率贝叶斯决策); 对于二类决策, 若 $P(\omega_1|\mathbf{x}) > P(\omega_2|\mathbf{x})$,

则 $\mathbf{x} \in \omega_1, \alpha = \alpha_1$, 反之 $\mathbf{x} \in \omega_2, \alpha = \alpha_2$

情况二：考虑拒实，即 $\alpha = (\alpha_1, \alpha_2, reject)$, $\lambda(\alpha_i|\omega_j) = \begin{cases} 0, & i = j \\ \lambda_s, & i \neq j \\ \lambda_r, & reject \end{cases}$

计算类别的条件风险得： $R(\alpha_i|\mathbf{x}) = \sum_{j=1}^c \lambda(\alpha_i|\omega_j)P(\omega_j|\mathbf{x})$

此时： $R_i(\mathbf{x}) \triangleq R(\alpha_i|\mathbf{x}) = \begin{cases} \lambda_s[1 - P(\omega_i | \mathbf{x})], & i = 1, 2 \\ \lambda_r, & reject \end{cases}$, 决策规则为 $\arg \min_i R_i(\mathbf{x})$

3. 对于 c 类问题，假定各类条件概率密度函数均为多元正态分布。在最小错误率贝叶斯决策的框架下，请写出其判别函数；请分别指出在什么情况下可以获得最小距离分类器，在什么情况下可以得到线性判别函数。

在最小错误率贝叶斯决策的框架下：假设各类条件概率密度函数（似然）为多元正态分布，即 $p(\mathbf{x}|\omega_i) \sim N(\mu_i, \Sigma_i), i = 1, 2, \dots, c$ ，采用的判别函数为二次判别函数 (Quadratic Discriminant Function, QDF):

$$\begin{aligned} g_i(\mathbf{x}) &= \ln(p(\mathbf{x} | \omega_i)) + \ln(P(\omega_i)) \\ &= -\frac{1}{2}(\mathbf{x} - \mu_i)^T \Sigma_i^{-1}(\mathbf{x} - \mu_i) - \frac{d}{2} \ln(2\pi) - \frac{1}{2} \ln(|\Sigma_i|) + \ln(P(\omega_i)) \\ &\quad (i = 1, 2, \dots, c) \end{aligned}$$

情形一：假设 $\Sigma_i = \sigma^2 \mathbf{I} \in \mathbb{R}^{d \times d}, i = 1, 2, \dots, c$

此时，QDF 可化为

$$\begin{aligned} g_i(\mathbf{x}) &= -\frac{1}{2\sigma^2}(\mathbf{x} - \mu_i)^T(\mathbf{x} - \mu_i) - \underbrace{\frac{d}{2} \ln(2\pi) - \frac{1}{2} \ln(\sigma^{2d})}_{Const.} + \ln(P(\omega_i)) \\ &\Leftrightarrow -\frac{1}{2\sigma^2}(\mathbf{x} - \mu_i)^T(\mathbf{x} - \mu_i) + \ln(P(\omega_i)) \\ &= -\frac{1}{2\sigma^2} \underbrace{\|\mathbf{x} - \mu_i\|^2}_{ED} + \ln(P(\omega_i)) \end{aligned}$$

(1) 当各类先验概率相等时，即 $P(\omega_i) = P(\omega_j)$ 时， $g_i(\mathbf{x}) = -\frac{1}{2\sigma^2}\|\mathbf{x} - \mu_i\|^2 + \ln(P(\omega_i))$
 $\Leftrightarrow g_i(\mathbf{x}) = -\frac{1}{2\sigma^2}\|\mathbf{x} - \mu_i\|^2$ ，此时最小错误率贝叶斯规则即为选取样本 \mathbf{x} 对各类均值向量 μ_i 距离最近的一类作为其分类，这种分类器被称为最小距离分类器

(2) 当各类先验概率不相等时，即 $P(\omega_i) \neq P(\omega_j)$ 时，此时：

$$\begin{aligned} g_i(\mathbf{x}) &= -\frac{1}{2\sigma^2}(\mathbf{x} - \mu_i)^T(\mathbf{x} - \mu_i) + \ln(P(\omega_i)) \\ &= -\frac{1}{2\sigma^2}(\mathbf{x}^T \mathbf{x} - 2\mu_i^T \mathbf{x} + \mu_i^T \mu_i) + \ln(P(\omega_i)) \end{aligned}$$

$$\Leftrightarrow \underbrace{\left(\frac{1}{\sigma^2}\boldsymbol{\mu}_i^T\right)}_{\mathbf{w}_i^T} \mathbf{x} + \underbrace{\left(-\frac{1}{2\sigma^2}\boldsymbol{\mu}_i^T \boldsymbol{\mu}_i + \ln(P(\omega_i))\right)}_{w_{i0}}$$

此时可以得到 $g_i(\mathbf{x}) = \mathbf{w}_i^T \mathbf{x} + w_{i0}$, 判别函数 $g_i(\mathbf{x})$ 为 \mathbf{x} 的线性函数, 因此也称其为线性判别函数 (Linear Discriminant Function, LDF), 这种分类器被称为线性分类器

4. 针对概率密度函数参数估计问题, 请描述最大似然估计的计算步骤 (包含已知条件以及求解任务)。

最大似然估计 (MLE)

- 已知条件: (1) 类条件概率密度 $p(\mathbf{x}|\omega_i)$ 的函数形式 (如: 服从 n 维正态分布)
 (2) 类条件概率密度 $p(\mathbf{x}|\omega_i)$ 独立同分布, 且不同类别的参数是独立的
 (3) 样本集: $\mathbf{D} = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n\}$
 (4) MLE 假设 $\boldsymbol{\theta}$ 是未知但固定的, 即 $P(\boldsymbol{\theta}) = 1$

求解任务: 求解能够使获得样本集 \mathbf{D} 可能性最大的参数 $\boldsymbol{\theta}$, 即 $\arg \max_{\boldsymbol{\theta}} P(\mathbf{D}|\boldsymbol{\theta})$

计算步骤: (1) 计算似然函数或对数似然函数:

$$l(\boldsymbol{\theta}) = P(\mathbf{D}|\boldsymbol{\theta}) = P(\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n|\boldsymbol{\theta}) = \prod_{i=1}^n p(\mathbf{x}_i|\boldsymbol{\theta})$$

$$H(\boldsymbol{\theta}) = \ln l(\boldsymbol{\theta}) = \ln \prod_{i=1}^n p(\mathbf{x}_i|\boldsymbol{\theta}) = \sum_{i=1}^n \ln(p(\mathbf{x}_i|\boldsymbol{\theta}))$$

- (2) 求解似然函数或对数似然函数的极值, 得到估计参数集:

$$\frac{\partial l(\boldsymbol{\theta})}{\partial \boldsymbol{\theta}} = 0 \Leftrightarrow \nabla_{\boldsymbol{\theta}}(l(\boldsymbol{\theta})) = \left[\frac{\partial l(\boldsymbol{\theta})}{\partial \theta_1}, \frac{\partial l(\boldsymbol{\theta})}{\partial \theta_2}, \dots, \frac{\partial l(\boldsymbol{\theta})}{\partial \theta_m} \right]^T = 0$$

$$\frac{\partial H(\boldsymbol{\theta})}{\partial \boldsymbol{\theta}} = 0 \Leftrightarrow \nabla_{\boldsymbol{\theta}}(H(\boldsymbol{\theta})) = \sum_{i=1}^n \nabla_{\boldsymbol{\theta}} \ln(p(\mathbf{x}_i|\boldsymbol{\theta})) = 0$$

$$\boldsymbol{\theta} = [\theta_1, \theta_2, \dots, \theta_m]^T$$

5. 针对样本的类条件概率密度函数估计问题, 请描述贝叶斯估计的计算步骤 (包含已知条件以及求解任务)。

贝叶斯估计

- 已知条件: (1) 待估参数的先验概率: $p(\boldsymbol{\theta})$
 (2) 样本集: $\mathbf{D} = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n\}$ (并假设数据为独立采样获取)


求解任务: 使后验概率 $p(\boldsymbol{\theta}|\mathbf{D})$ 最大, 即 $\arg \max_{\boldsymbol{\theta}} P(\boldsymbol{\theta}|\mathbf{D})$, 并最终基于有限的样本集 \mathbf{D} 估计后验概率密度函数 $p(\mathbf{x}|\mathbf{D})$

计算步骤: (1) 计算后验概率密度函数:

$$p(\boldsymbol{\theta}|\mathbf{D}) = \frac{p(\mathbf{D}|\boldsymbol{\theta})p(\boldsymbol{\theta})}{\int_{\boldsymbol{\theta}} p(\mathbf{D}|\boldsymbol{\theta})p(\boldsymbol{\theta})d\boldsymbol{\theta}} = \frac{\prod_{i=1}^n p(\mathbf{x}_i|\boldsymbol{\theta})p(\boldsymbol{\theta})}{\int_{\boldsymbol{\theta}} \prod_{i=1}^n p(\mathbf{x}_i|\boldsymbol{\theta})p(\boldsymbol{\theta})d\boldsymbol{\theta}} = \alpha \prod_{i=1}^n p(\mathbf{x}_i|\boldsymbol{\theta})p(\boldsymbol{\theta})$$

$$(2) \text{ 计算平均估计量: } \hat{\boldsymbol{\theta}} = \int_{\boldsymbol{\theta}} \boldsymbol{\theta} p(\boldsymbol{\theta}|\mathbf{D}) d\boldsymbol{\theta}$$

(3) 估计后验数据分布：



$$\begin{aligned}
 p(\mathbf{x}|\mathbf{D}) &= \int_{\theta} p(\mathbf{x}, \theta|\mathbf{D}) d\theta = \int_{\theta} \frac{p(\mathbf{x}, \theta, \mathbf{D})}{p(\mathbf{D})} d\theta \\
 &= \int_{\theta} \frac{p(\mathbf{x}|\theta, \mathbf{D})p(\theta, \mathbf{D})}{p(\mathbf{D})} d\theta \\
 &= \int_{\theta} p(\mathbf{x}|\theta, \mathbf{D})p(\theta|\mathbf{D}) d\theta \\
 &= \int_{\theta} p(\mathbf{x}|\theta)p(\theta|\mathbf{D}) d\theta \\
 &\quad (\text{给定参数 } \theta \text{ 时, 样本分布于训练集 } \mathbf{D} \text{ 无关})
 \end{aligned}$$

6. 请指出最大似然估计和贝叶斯估计的不同之处。

不同点：(1) 对估计参数的假设不同： MLE 假设待估计的参数是未知但固定的变量，贝叶斯估计则假设待估计的参数是一个随机变量也因此， MLE 为点估计，贝叶斯估计为对分布估计

(2) 研究的对象不同：因为对待估计参数的假设不同， MLE 重点研究样本空间，而贝叶斯估计则认为样本是固定的，则重点研究待估计参数的分布